

FUNDAÇÃO GETULIO VARGAS - FGV

TRABALHO 1

Ana Paula Pudo

MBA Business Analytics e Big Data | Análise de Séries Temporais

Prof. Alvaro Villarinho

Brasília
2022

SUMÁRIO

LISTA DE GRÁFICOS.....	2
1. Introdução.....	3
2. Análise Exploratória.....	3
2.1 Comportamento Sazonal da demanda	6
2.2 Corte da série temporal original.....	7
3. Teste de modelo Holt-Winter (Aditivo e Multiplicativo).....	8
4.1 Comparação dos modelos Holt-Winter Aditivo e Multiplicativo	9
4. Correlogramas ACF e PACF.....	10
5. Testes de raiz-unitária	11
6. Modelagem SARIMA	12
7. Melhor modelo para Akaike.....	13
8. Previsão para até dezembro/2022.....	13
9. Conclusões	13

LISTA DE GRÁFICOS

Gráfico 1: Média Histórica Mensal de Entrega de Fertilizantes por mil toneladas
Gráfico 2: Média Histórica Anual de Entrega de Fertilizantes por mil toneladas
Gráfico 3: Entrega de Fertilizantes (por mês)
Gráfico 4: Entrega de Fertilizantes (Série Histórica em Toneladas)
Gráfico 5: Decomposições da série
Gráfico 6: Sazonalidade da série temporal
Gráfico 7: Série de tempo Jan/2010 - Out/2018
Gráfico 8: Decomposição da Serie Treino (Jan/2010 – Dez/2018)
Gráfico 9: Modelo Holt-Winter Aditivo
Gráfico 10: Modelo Holt-Winter Multiplicativo
Gráfico 11: Acurácia dos modelos HWA e HWM
Gráfico 12: Teste do modelo HWA e HWM
Gráfico 13: Correlogramas ACF e PACF
Gráfico 14: Projeção dos modelos testados
Gráfico 15: Projeção de Entregas ao Mercado (até dez/22)

1. Introdução

O agronegócio tem um peso importante na economia brasileira, refletido de modo especial no desempenho registrado em nossa balança comercial. Segundo dados da Secretaria Especial de Comércio Exterior e Assuntos Internacionais (SECINT), vinculada ao Ministério da Economia, o Brasil registrou um crescimento de exportações do setor de 19,7% entre os anos de 2020 e 2021. Em valores correntes, foram US\$ 120,6 bilhões (valor recorde da série histórica) vendidos para o mercado externo. A alta das commodities no cenário internacional ao longo do ano passado foi também decisiva para esse desempenho histórico.

Mas não é apenas a subida dos preços internacionais que justifica o bom desempenho do agronegócio. O setor tem investido muito em tecnologia para otimizar sua capacidade produtiva ao longo das últimas décadas, sendo a Embrapa um dos órgãos mais importantes nesse sentido, trazendo soluções aos produtores através de inovação e pesquisa científica.

Existe uma série de desafios que podem impactar a produção do setor. Condições climáticas, equilíbrio químico do solo, espaço disponível... as variáveis apontam para um único caminho para atingir o sucesso: otimização da produção. E é aí que entra em cena um dos elementos mais importantes para qualquer produtor, de pequeno, médio ou grande porte: os fertilizantes.

Eles são compostos utilizados para fornecer nutrientes às plantações, reduzindo as perdas decorrentes de condições adversas do cultivo. Eles variam de acordo com os tipos de plantações e de solos utilizados, podendo trazer elementos de correção ou de suplementação da terra plantada. Os fertilizantes ocupam um papel importante na cadeia do agronegócio e são investimentos essenciais para os produtores.

Este estudo se propõe a analisar os números de fertilizantes entregues ao mercado brasileiro (trata-se da soma da produção nacional + o volume importado para abastecer o mercado, uma vez que apenas a produção brasileira é insuficiente para atender a demanda interna), considerando o período de 1998 até outubro de 2021. A base de dados utilizada é da Associação Nacional de Difusão de Adubos (ANDA).

2. Análise Exploratória

Em uma breve análise inicial, os dados apresentam a série histórica de entrega de fertilizantes no Brasil entre o período de janeiro de 1998 a outubro de 2021, totalizando 283 meses de informações, ou quase 24 anos de dados. A imagem abaixo apresenta a média de entrega mensal de fertilizantes:




Gráfico 1: Média Histórica Mensal de Entrega de Fertilizantes por mil toneladas

Conforme observado na imagem acima, vimos que os meses de maior entrega de fertilizantes na série histórica foram agosto, setembro e outubro, que é o período de entressafra de várias culturas, quando produtores organizam a compra de insumos e de equipamentos, apoiado muitas vezes em contratação de crédito, para iniciar o período de plantio das principais lavouras.




Gráfico 2: Média Histórica Anual de Entrega de Fertilizantes por mil toneladas

A imagem acima apresenta um aumento da entrega de fertilizantes conforme o decorrer dos anos. Este fato está diretamente relacionado ao aumento do consumo de alimentos e a adoção de políticas públicas que buscam a melhoria da produtividade dos produtores de grãos no Brasil.

De acordo com a série histórica analisada, percebe-se que o volume de entregas de fertilizantes ao mercado tem avançado ao longo dos anos, com um pico registrado no mês de julho/2021.

É perceptível também um volume maior de entregas no período compreendido entre os meses de maio e agosto, que é o período de entressafra de cultivos como soja e milho, e que também os principais produtores organizam os insumos necessários para o plantio da próxima safra, incluindo compra de insumos e de maquinário.

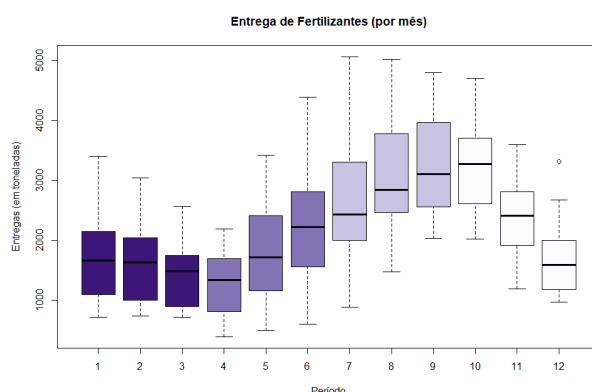


Gráfico 3: Entrega de Fertilizantes (por mês)




Gráfico 4: Entrega de Fertilizantes (Série Histórica em Toneladas)

Quando realizamos a decomposição, fica mais evidente o comportamento de padrão aditivo da série histórica, uma vez que a sua sazonalidade não apresenta crescimento conforme o aumento da entrega de fertilizantes colocados no mercado. É uma série de tempo com uma tendência crescente.

No período de março de 2020 com a chegada da pandemia do Covid-19, é possível ver uma queda na demanda quando comparada com o ano de 2019 e sinais de uma recuperação em 2021 com um crescimento gradativo.

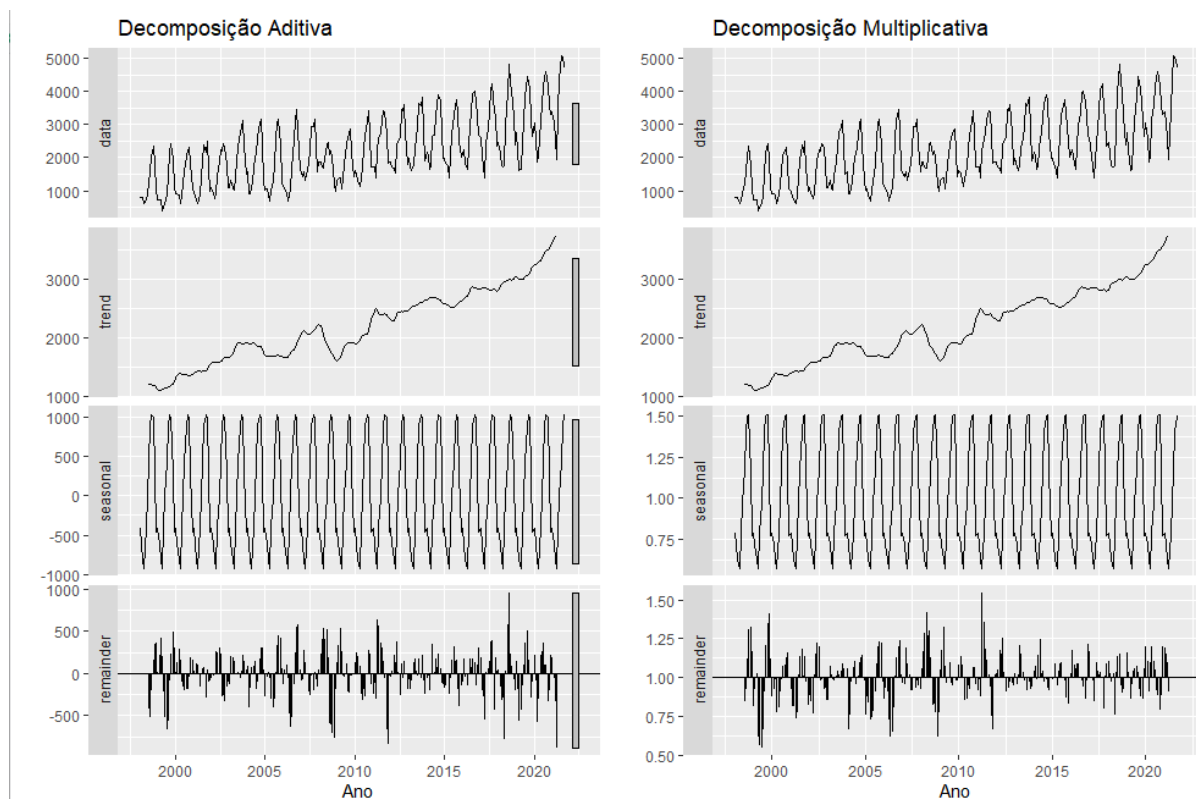


Gráfico 5: Decomposições da série

2.1 Comportamento Sazonal da demanda

De acordo com a visualização abaixo, que traz um gráfico sobre o comportamento sazonal da demanda, percebe-se que nos meses de julho, agosto e outubro há um padrão que é mantido em todos os anos observados nesta série temporal.




Gráfico 6: Sazonalidade da série temporal

2.2 Corte da série temporal original

A partir de uma análise inicial da série completa de 1998 a 2021, observa-se que há uma acomodação das oscilações após 2009. A partir dessa percepção, foi decidido fazer um corte de treino do período entre janeiro de 2010 e dezembro de 2018 e outro corte de teste de janeiro de 2019 até outubro de 2021. Esses cortes serão utilizados para testar o melhor modelo de previsão. Mesmo com o corte da janela de treino, a série se manteve com um padrão de comportamento aditivo.




Gráfico 7: Série de tempo Jan/2010 - Out/2018

Fonte: ANPA




Gráfico 8: Decomposição da Serie Treino (Jan/2010 – Dez.2018)

3. Teste de modelo Holt-Winter (Aditivo e Multiplicativo)

Foi aplicado o modelo HW Aditivo e Multiplicativo na série de tempo de treinamento. A partir apenas da observação dos gráficos, fica difícil dizer qual o melhor modelo, por esta razão é necessário verificar a acurácia.

O modelo Aditivo apresentou pelo RMSE 265,34 e MAPE 8,28, o menor índice de erro, a visualização comparativa esta disposta no Gráfico 11, demonstrado na sequência abaixo.




Gráfico 9: Modelo Holt-Winter Aditivo




Gráfico 10: Modelo Holt-Winter Multiplicativo




Gráfico 11: Acurácia dos modelos HWA e HWM

4.1 Comparação dos modelos Holt-Winter Aditivo e Multiplicativo

Após a aplicação dos modelos na série de treinamento, foi acrescentada a camada da série de teste para verificar a evolução do modelo. Tanto o modelo HWA e HWM visualmente parecem ser bons modelos, uma vez que acompanham a tendência e sazonalidade da série como um todo, sendo o modelo HWA com o menor erro conforme mencionado anteriormente. Adiante será apresentado outro modelo para uma melhor avaliação da previsão para 2022 e escolha do melhor modelo.

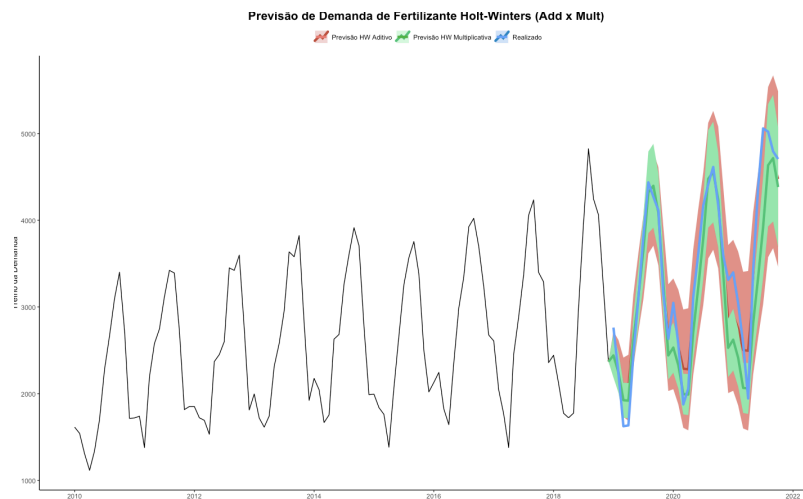


Gráfico 12: Teste do modelo HWA e HWM

4. Correlogramas ACF e PACF

Nesta etapa foram plotados dois correlogramas baseados nos dados *ts.treino* criado neste estudo:

- * ACF - Regressão em relação aos erros
- * PACF - Regressão em relação contra si própria

Para melhor visualização e análise, empregamos o pacote TStudio, onde por meio da função `ts_cor(ts.treino)` é possível identificar um ACF (ordem 2), PACF (ordem 4) e o Seasonal (em vermelho).

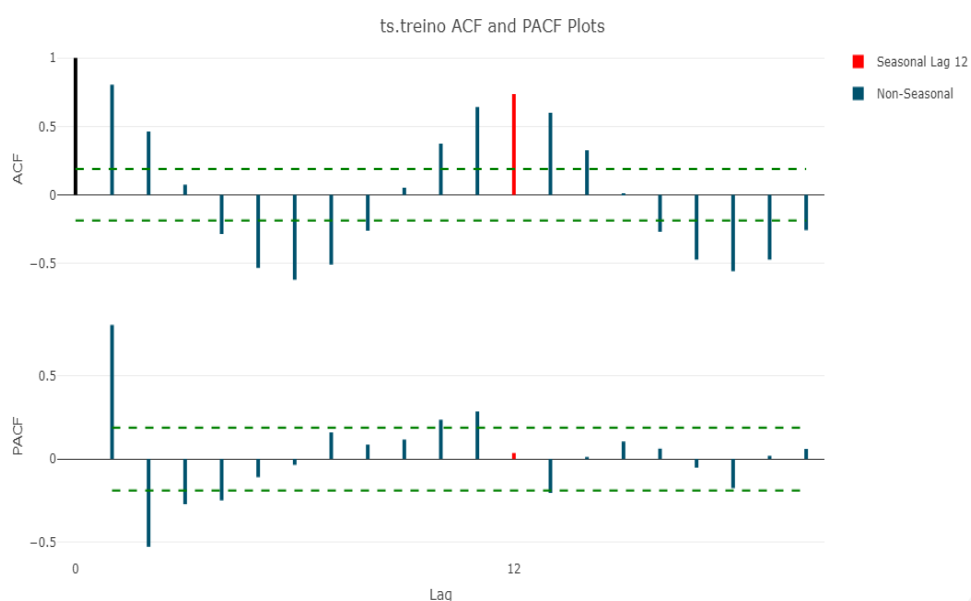


Gráfico 13: Correlogramas ACF e PACF

Nesta etapa não foram exauridos todos os métodos possíveis em uma análise de séries temporais. Outros modelos poderiam ser utilizados para melhoria e refinamento da base. Contudo, este estudo vai focar na utilização do Modelo SARIMA, que já realiza de forma automática o processo.

5. Testes de raiz-unitária

Necessário para catalogação da série temporal em estudo como sendo ou não estacionária, serão adotados a seguir três testes formais: ADF (Augmented Dickey-Fuller), PP (Phillips-Perron) e KPSS (Kwiatkoski-Phillips-Schmidt-Shin).

Fazendo uso dessas três técnicas, serão realizados testes estatísticos onde serão validadas as hipóteses. Assim, será possível determinar se os dados nesta análise são suficientemente para determinar se a série é ou não estacionaria.

6.1 ADF (Augmented Dickey-Fuller)

Hipótese:

H0: A série não é estacionária

Ha: A série é estacionária

Resultado: Com um p-value = 0,01

É estatisticamente significativa, rejeita-se H0 em favor de Ha.

A série é estacionária

6.2 PP (Phillips-Perron)

Hipótese:

H0: A série não é estacionária

Ha: A série é estacionária

Resultado: Com um p-value = 0,01

É estatisticamente significativa, rejeita-se H0 em favor de Ha.

A série é estacionária

6.3 KPSS (Kwiatkoski-Phillips-Schmidt-Shin).

Hipótese:

H0: A série é estacionária

Ha: A série não é estacionária

Resultado: Com um p-value = 0,05396

É estatisticamente significativa, rejeita-se H0 em favor de Ha.

A série não é estacionária

Diante dos testes, não é possível afirmar se a série é ou não estacionária. Contudo, existem fortes indícios de que a série temporal é uma série estacionária, já que, dos 3 testes, 2 (PP e ADF) apontam para esse caminho.

6. Modelagem SARIMA

O modelo SARIMA pode ser considerado um refinamento do método ARIMA. O SARIMA considera uma sazonalidade de uma série, permitindo uma melhor previsão das estimativas, potencializando a possibilidade de explicar o comportamento para a variável resposta.

O resultado desse processamento foi a modelagem ARIMA (1,0,0) (0,1,1) [12], isso significa que o modelo para parte não sazonal $(p,d,q) = (1,0,0)$ tem 1 lag na ordem da parte autorregressiva, 0 no grau de defasagem e 0 na ordem da média móvel enquanto que na parte sazonal do modelo $(P,D,Q) = (0,1,1)$ precisou de 0 nos termos da auto regressão, 1 na defasagem e 1 na Média Móvel.

O gráfico abaixo mostra a representação do ts.treino (Original), AutoArima (Modelo) e o Forecast do AutoArima (Previsão)




Gráfico 14: Projeção dos modelos testados

O modelo proposto projetado se mostrou ao longo dos valores no tempo muito semelhante ao ts.treino (original) utilizado nesta modelagem. A previsão proposta se mostrou bastante coerente e utiliza os dados para projetar uma previsão futura por meio de métodos estatísticos a partir da janela temporal de janeiro de 2019 até novembro de 2021.

7. Melhor modelo para Akaike

O melhor modelo a partir do critério de aceitação AIC (Akaike) foi o *AUTOARIMA AR(1) - ARIMA(1,0,0)(0,1,1)[12] with drift*. Esse possui o menor valor aferido (1362.47), indicando o menor erro entre os modelos aplicados, ou seja, aponta que o modelo AUTOARIMA é o mais indicado a ser adotado.

8. Previsão para até dezembro/2022

É possível notar que a previsão estabelecida até o período de dezembro de 2022 pelo modelo Sarima acompanha a tendência e sazonalidade da série base de teste, concluindo assim que o modelo é adequado.




Gráfico 15: Projeção de Entregas ao Mercado (até dez/22)

9. Conclusões

Pelas projeções dos modelos analisados neste estudo, é possível afirmar que o movimento de sazonalidade deverá se repetir ao longo de 2022. Contudo, as quantidades de fertilizantes colocados no mercado podem variar de acordo com o cenário mundial. A previsão de preços das commodities, por exemplo, é uma variável econômica fundamental para apontar se os volumes negociados em 2022 baterão os recordes do ano anterior.

Os modelos mostram a importância de uma análise de série temporal completa, considerando modelos e hipóteses, e permitindo avaliar a sazonalidade dos indicadores.

Os modelos são grandes aliados do processo de decisão macroeconômico e apontam projeções bastante seguras dos cenários possíveis. Contudo, é importante avaliar se existem outras variáveis que podem interferir no processo de tomada de decisão.